فصل ۱: مقدمه‌ای از یادگیری ماشین

مقدمه

یادگیری ماشین طراحی و مطالعه نرم‌افزاری است که از تجربیات گذشته برای تصمیم‌گیری در آینده استفاده می‌کند. هدف اساسی یادگیری ماشین تعمیم یا القای قاعده‌ای ناشناخته از داده‌هایی است که در دسترس می‌باشند. مثال متعارف یادگیری ماشین، فیلتر کردن هرزنامه (spam) است. با مشاهده هزاران ایمیل که قبلاً به عنوان هرزنامه (spam) یا نامه معمولی (ham) برچسب‌گذاری شده بودند، می‌توانند پیام‌های جدید را طبقه‌بندی کنند.

آرتور ساموئل (Arthur Samuel)، دانشمند کامپیوتر که پیشگام مطالعه هوش مصنوعی بود، گفت که یادگیری ماشین "مطالعه‌ای است که به کامپیوتر توانایی یادگیری بدون برنامه‌ریزی صریح را می‌دهد." در طول دهه‌های ۱۹۵۰ و ۱۹۶۰، ساموئل برنامه‌هایی را توسعه می‌داد که پیرامون بازی چکرز بودند. در حالی که قوانین چکرز ساده است، اما برای شکست دادن رقبای ماهر، استراتژی‌های پیچیده‌ای لازم است. ساموئل هرگز به صراحت این استراتژی‌ها را برنامه‌نویسی نکرد، اما از طریق تجربه انجام هزاران بازی، این برنامه رفتارهای پیچیده‌ای را آموخت که به او اجازه می‌داد بسیاری از حریفان انسانی را شکست دهد.

یک نقل قول معروف از دانشمند کامپیوتر، تام میچل (Tom Mitchell)، که یادگیری ماشین را به صورت رسمی‌تر تعریف می‌کند: "می‌توان گفت برنامه‌ای با توجه به برخی از

وظایف T و اندازه‌گیری عملکرد P می‌تواند تجربه E را یاد بگیرد، اگر عملکرد آن در T همانی باشد که توسط P اندازه‌گیری شده است، عملکرد برنامه با تجربه E بهبود می‌یابد."
به عنوان مثال، تصور کنید که مجموعه‌ای از تصاویر دارید که هر تصویر یا یک سگ یا گربه را به تصویر می‌کشد. یک کار می‌تواند مرتب‌سازی تصاویر به مجموعه‌های جداگانه عکس سگ و گربه باشد. یک برنامه می‌تواند با مشاهده تصاویری که قبلاً مرتب شده‌اند، انجام این کار را بیاموزد و می‌تواند با محاسبه درصد تصاویر طبقه‌بندی شده صحیح، عملکرد آن را ارزیابی کند.



شکل (۱-۱): آرتور ساموئل (پدر هوش مصنوعی)

یادگیری از طریق تجربه

سیستم‌های یادگیری ماشین اغلب به عنوان یادگیری از تجربه با نظارت (supervised) یا بدون نظارت (unsupervised) توصیف می‌شوند. در مسائل یادگیری تحت نظارت، یک برنامه با یادگیری از جفت ورودی و خروجی دارای برچسب، یک خروجی را برای ورودی که دیده نشده است پیش‌بینی می‌کند. در یادگیری بدون نظارت، برنامه از داده‌های دارای برچسب یاد نمی‌گیرد. در عوض، سعی در کشف الگوها در داده‌ها دارد. به عنوان مثال، فرض کنید که شما داده‌های توصیف قد و وزن افراد را جمع‌آوری کرده‌اید. نمونه‌ای از یک مسئله یادگیری بدون نظارت تقسیم داده‌ها به گروه‌ها است. در یک برنامه ممکن است گروه‌هایی تولید شود که مربوط به مردان و زنان، یا کودکان و بزرگسالان باشد.

حال فرض کنید که داده‌ها با جنسیت فرد نیز برچسب‌گذاری شده باشد. مثالی از یک مسئله یادگیری تحت نظارت، القای قاعده‌ای برای پیش‌بینی مرد یا زن بودن شخص بر اساس قد و وزن است. ما در مورد الگوریتم‌ها و نمونه‌هایی از یادگیری با نظارت و بدون نظارت در فصل‌های بعدی توضیح خواهیم کرد.

برخی از انواع مسائل، به نام یادگیری نیمه نظارت شده است، که هم از داده‌های نظارت شده و هم از نظارت نشده استفاده می‌کنند. این مسائل در طیف بین یادگیری نظارت شده و بدون نظارت قرار دارند. نمونه‌ای از یادگیری ماشینی نیمه نظارت شده، یادگیری تقویت کننده (Reinforcement Learning) است که در آن یک برنامه برای تصمیمات خود بازخورد می‌گیرد، اما ممکن است بازخورد با یک تصمیم واحد همراه نباشد. به عنوان مثال، یک برنامه یادگیری تقویت کننده یاد می‌گیرد یک بازی ویدیویی مانند Super Mario Bros را انجام دهد. ممکن است با اتمام مرحله یا دریافت امتیاز زیاد پاداشی را دریافت کند و در صورت از دست دادن یک جان مجازات شود.

وظایف یادگیری ماشین

دو مورد از رایج‌ترین وظایف یادگیری ماشین تحت نظارت، کلاسه‌بندی و رگرسیون است. در کلاسه‌بندی، برنامه باید یاد بگیرد که مقادیر گسسته را برای متغیرهای پاسخ از یک یا چند متغیر توضیحی پیش‌بینی کند. یعنی برنامه باید محتمل‌ترین گروه، کلاس یا برچسب را برای مشاهدات جدید پیش‌بینی کند. برنامه‌های کلاسه‌بندی شامل پیش‌بینی افزایش یا سقوط قیمت سهام، یا تصمیم‌گیری در مورد تعلق یک مقاله خبری به بخش سیاست یا اوقات فراغت می‌باشد. در مسائل رگرسیون برنامه باید مقدار یک متغیر را پیش‌بینی کند، مانند پیش‌بینی فروش کالای جدید یا دستمزد یک شغل براساس توضیحات آن، از جمله مسائل رگرسیون است. مشابه رده‌بندی، رگرسیون نیاز به یادگیری تحت نظارت دارند.

یک کار معمول یادگیری بدون نظارت، کشف گروه‌هایی به نام خوشه در داده‌های آموزش است. این وظیفه، تجزیه خوشه‌ای نامیده می‌شود، که مشاهدات را به گروه‌ها اختصاص می‌دهد به طوری که مشاهدات درون گروه‌ها براساس برخی از اندازه‌گیری‌ها شباهت بیشتری نسبت به سایر گروه‌ها دارند؛ و خوشه‌بندی اغلب برای کاوش یک مجموعه داده استفاده می‌شود. به عنوان مثال، در مجموعه‌ای از نقدهای یک فیلم، یک الگوریتم خوشه‌بندی ممکن است مجموعه‌ای از نقدهای مثبت و منفی را کشف کند در حالی‌که نمی‌تواند خوشه‌ها را به عنوان "مثبت" یا "منفی" برچسب‌گذاری کند. بدون نظارت، فقط می‌تواند مشاهدات گروه‌بندی شده را اندازه‌گیری کند. یک کاربرد متداول خوشه‌بندی،

کشف بخش‌هایی از مشتری در بازار یک محصول است. با درک اینکه چه ویژگی‌هایی در گروه‌های خاص مشتری مشترک است، بازاریابان می‌توانند تصمیم بگیرند که چه جنبه‌هایی از کمپین هایشان باید مورد تأکید قرار گیرد. خوشه‌بندی توسط سرویس‌های رادیویی اینترنتی نیز استفاده می‌شود. به عنوان مثال، با توجه به مجموعه‌ای از آهنگ‌ها، یک الگوریتم خوشه‌بندی ممکن است بتواند آهنگ‌ها را بر اساس ژانرهای آن‌ها گروه‌بندی کند. با استفاده از معیارهای مشابهت مختلف، الگوریتم خوشه‌بندی یکسان ممکن است آهنگ‌ها را بر اساس کلیدهای آن‌ها یا بر اساس سازهای موجود در آن‌ها گروه‌بندی کند.

کاهش ابعاد یکی دیگر از کارهای معمول یادگیری بدون نظارت است. برخی از مشکلات ممکن است حاوی هزاران یا حتی میلیون‌ها متغیر توضیحی باشد که کار با آن‌ها از نظر محاسباتی هزینه بر است. بعلاوه، اگر برخی از متغیرهای توضیحی نویز را بگیرند یا به رابطه اساسی مربوط نباشند، ممکن است توانایی برنامه برای تعمیم کاهش یابد. کاهش ابعاد، فرآیند کشف متغیرهای توضیحی است که بیشترین تغییرات را در متغیر پاسخ به خود اختصاص می‌دهد.

برای تجسم داده‌ها می‌توان از کاهش ابعاد نیز کمک گرفت. تجسم یک مسئله رگرسیون مانند پیش‌بینی قیمت یک خانه از اندازه آن آسان است. اندازه خانه را می‌توان در محور x ترسیم کرد و قیمت خانه را می‌توان بر روی محور y رسم کرد. به همین ترتیب، هنگامی که متغیر توضیحی دوم اضافه می‌شود، مسئله رگرسیون قیمت مسکن را به راحتی می‌تواند محاسبه کند. به عنوان مثال می‌توان تعداد حمام‌های خانه را در محور z رسم کرد. با وجود این اگر هزاران متغیر توضیحی داشته باشیم تصور آن غیرممکن می‌شود.

داده‌های آموزش و داده‌های آزمون

مشاهدات در مجموعه آموزش شامل داده‌هایی است که الگوریتم برای یادگیری استفاده می‌کند. در مسائل یادگیری نظارت شده، هر مشاهده متشکل از یک متغیر پاسخ مشاهده شده و یک یا چند متغیر توضیحی مشاهده شده است. مجموعه آزمون مجموعه مشابه مشاهداتی است که در ارزیابی عملکرد مدل با کمک از برخی معیارها استفاده می‌شود. هیچ مشاهده‌ای از مجموعه آموزشی در مجموعه آزمون گنجانده نمی‌شود. اگر مجموعه آزمون شامل نمونه‌هایی از مجموعه آموزش باشد، ارزیابی اینکه الگوریتم تعمیم را از مجموعه

آموزش آموخته است یا به سادگی آن را حفظ کرده است دشوار خواهد بود. برنامه‌ای که به خوبی تعمیم داده شود قادر خواهد بود با داده‌های جدید وظیفه را به طور موثر انجام دهد. در مقابل، برنامه‌ای که با یادگیری یک مدل بیش از حد پیچیده داده‌های آموزش را به خاطر می‌سپارد، می‌تواند مقادیر متغیر پاسخ را برای مجموعه آموزش به طور دقیق پیش‌بینی کند، اما در پیش‌بینی مقدار متغیر پاسخ برای مثال‌های جدید ناموفق خواهد بود.

بیش برازش (Overfitting) یادگیری ماشین به مدلی اطلاق می‌شود که داده‌های آموزش را به خوبی مدل می‌کند. بیش برازش هنگامی اتفاق می‌افتد که یک مدل جزئیات و نویز را در داده‌های آموزش بیاموزد تا حدی که بر عملکرد مدل روی داده‌های جدید تأثیر منفی بگذارد. متعادل‌سازی حفظ و تعمیم، بیش برازش و کم برازش، مسئله مشترک بسیاری از الگوریتم‌های یادگیری ماشین است.

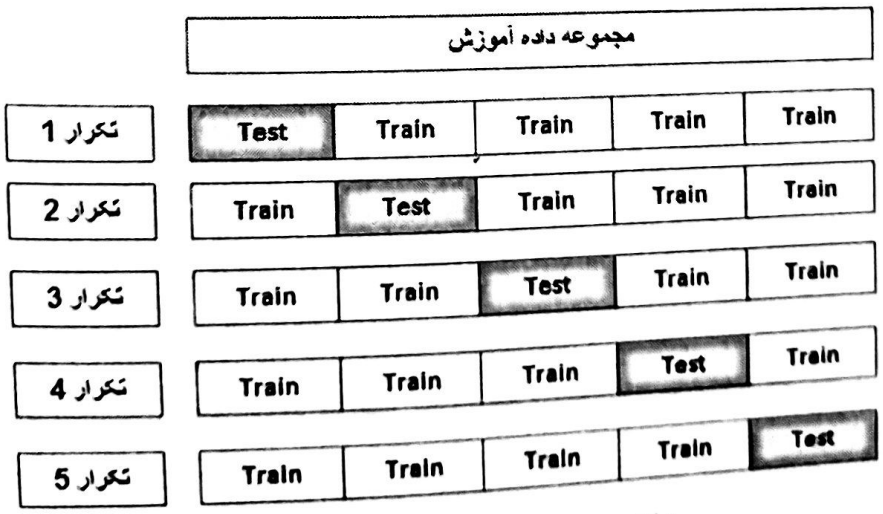
گاهی اوقات علاوه بر داده‌های آموزش و آزمون، به یک سری مشاهدات دیگر، که مجموعه اعتبارسنجی (Validation) یا نگهداری (hold-out) نامیده می‌شود، نیاز می‌باشد. مجموعه اعتبارسنجی برای تنظیم متغیرهایی به نام ابرپارامترها (Hyper parameters)، که نحوه یادگیری مدل را کنترل می‌کنند، استفاده می‌شود. این برنامه هنوز در مجموعه آزمون ارزیابی می‌شود تا تخمینی از عملکرد آن در دنیای واقعی ارائه دهد. عملکرد مجموعه اعتبارسنجی نباید به عنوان برآورد عملکرد دنیای واقعی استفاده شود زیرا مدل به طور خاص با داده‌های اعتبارسنجی تنظیم شده است. تقسیم یک مجموعه مشاهدات به مجموعه‌های آموزش، اعتبارسنجی و آزمون یک کار متداول می‌باشد. در اندازه بخش‌ها هیچ الزام یا قانون خاصی وجود ندارد و ممکن است بسته به مقدار داده موجود متفاوت باشد. اختصاص ۵۰ درصد یا بیشتر داده‌ها به مجموعه آموزش، ۲۵ درصد به مجموعه آزمون و باقیمانده به مجموعه اعتبارسنجی یک راه معمول است.

بعضی از مجموعه‌های آموزشی ممکن است فقط شامل چند صد مشاهده باشد؛ و سایر مجموعه‌ها ممکن است میلیون‌ها مورد را شامل شود. فضای ذخیره‌سازی ارزان، افزایش قابلیت اتصال به شبکه، همه گیر بودن تلفن‌های هوشمند مجهز به سنسور و تغییر نگرش نسبت به حریم خصوصی، به وضعیت معاصر کلان داده‌ها (Big Data) یا مجموعه‌های آموزشی با میلیون‌ها یا میلیاردها نمونه کمک کرده است.

در این کتاب با مجموعه داده‌هایی که نیاز به پردازش موازی ده‌ها یا صدها ماشین دارند کار نخواهیم کرد، با این حال، الگوریتم‌های یادگیری ماشین نیز از "Garbage in – Garbage out" پیروی می‌کنند. به این معنی که اگر داده‌ها اشتباه باشند یا کیفیت کمی دارا باشند، خروجی محاسبات چندان دقیق نیست (یا کلاً غلط است). عملکرد یک الگوریتم آموزش دیده در یک مجموعه بزرگ از نویز، با داده‌های نامرتبط یا دارای برچسب نادرست نمی‌تواند از عملکرد الگوریتمی که روی مجموعه کوچک‌تر از داده‌ها آموزش داده شده است و نمایانگر مشکلات بیشتری در دنیای واقعی است، بهتر باشد.

بسیاری از مجموعه‌های آموزشی تحت نظارت به صورت دستی یا با فرایندهای نیمه خودکار تهیه می‌شوند. ایجاد یک مجموعه بزرگ از داده‌های تحت نظارت در برخی از حوزه‌ها هزینه‌بر می‌باشد. خوشبختانه، چندین مجموعه داده با scikit همراه است و به توسعه‌دهندگان اجازه می‌دهد روی آزمایش مدل‌ها تمرکز کنند بدون اینکه نگران جمع‌آوری داده‌های واقعی باشند. در طول توسعه، و به ویژه هنگامی که داده‌های آموزشی کمیاب هستند، از روشی به نام اعتبارسنجی متقابل (cross-validation) می‌توان برای آموزش و اعتبارسنجی الگوریتمی بر روی داده‌های مشابه استفاده کرد. در اعتبارسنجی متقابل، داده‌های آموزش به بخش‌هایی تقسیم‌بندی می‌شوند.

الگوریتم با استفاده از همه پارتیشن‌ها به جز یکی آموزش داده می‌شود و روی پارتیشن باقیمانده آزمایش صورت می‌گیرد. سپس پارتیشن‌ها چندین بار چرخانده می‌شوند تا الگوریتم بر روی تمام داده‌ها آموزش داده و ارزیابی شود. نمودار زیر اعتبارسنجی متقابل را با پنج پارتیشن نشان می‌دهد.



شکل (۱-۲): نمونه اعتبارسنجی متقابل

مقدمه‌ای برای scikit-learn

از زمان انتشار در سال ۲۰۰۷، scikit-learn به یکی از محبوب‌ترین کتابخانه‌های متن باز (open-source) یادگیری ماشین برای پایتون تبدیل شده است. scikit-learn الگوریتم‌هایی را برای یادگیری ماشین شامل طبقه‌بندی، رگرسیون، کاهش ابعاد، و خوشه‌بندی همچنین ماژول‌هایی برای استخراج ویژگی‌ها، پردازش داده‌ها و ارزیابی مدل‌ها فراهم می‌کند. scikit- learn از کتابخانه‌های معروف Python NumPy و matplotlib ساخته شده است. NumPy پایتون را گسترش می‌دهد تا از عملیات کارآمد روی آرایه‌های بزرگ و ماتریس‌های چند بعدی پشتیبانی کند. matplotlib ابزار تجسم و SciPy ماژول‌هایی برای محاسبات علمی فراهم می‌کند. scikit-learn برای تحقیقات دانشگاهی محبوب شده است زیرا دارای یک API کاملاً مستند، با کاربرد آسان و همه کاره می‌باشد. توسعه‌دهندگان می‌توانند با استفاده از scikit-learn فقط با تغییر چند خط کد، الگوریتم‌های مختلفی را آزمایش کنند.

scikit-learn برخی از پیاده‌سازی‌های معروف الگوریتم‌های یادگیری ماشین، مانند LIBSVM و LIBLINEAR را نیز شامل می‌شود. scikit-learn شامل مجموعه داده‌های مختلفی است که به توسعه‌دهندگان اجازه می‌دهد تا به جای به دست آوردن و تمیز کردن داده‌ها، روی الگوریتم‌ها تمرکز کنند.

نصب scikit-learn

برای نصب ممکن است نیاز باشد که پیش نیازهایی نصب گردد. بهتر است قبل از نصب صفحه https://scikit-learn.org/stable/install.html را مطالعه نمایید.

نصب در ویندوز

از دستور زیر در خط فرمان استفاده نمایید

```
$ pip install -U scikit-learn
```

برای بررسی نصب خود می‌توانید از دستورات زیر استفاده کنید

```
python -m pip show scikit-learn  # to see which version and where scikit-learn is installed
python -m pip freeze  # to see all packages installed in the active virtualenv
python -c "import sklearn; sklearn.show_versions()"
```

نصب در لینوکس

از دستور زیر در خط فرمان استفاده نمایید

```
pip3 install -U scikit-learn
```

برای بررسی نصب خود می‌توانید از دستورات زیر استفاده کنید

```
python3 -m pip show scikit-learn  # to see which version and where scikit-learn is installed
python3 -m pip freeze  # to see all packages installed in the active virtualenv
python3 -c "import sklearn; sklearn.show_versions()"
```

بررسی صحت نصب

برای بررسی اینکه scikit-learn به درستی نصب شده است، یک کنسول پایتون را باز کنید و موارد زیر را اجرا کنید

```
>>> import sklearn
>>> sklearn.__version__
```

panda

pandas یک کتابخانه متن باز است که ساختار داده‌ها و ابزارهای تجزیه و تحلیل را برای پایتون فراهم کرده است. ما از چند ابزار مناسب پاندا برای وارد کردن داده‌ها و محاسبه آمار خلاصه استفاده خواهیم کرد.

نصب panda در ویندوز

```
pip install pandas
```

نصب panda در لینوکس

```
pip3 install pandas
```

matplotlib

matplotlib کتابخانه‌ای است که برای ایجاد آسان نمودارها، هیستوگرام‌ها و نمودارهای دیگر با پایتون استفاده می‌شود. ما از آن برای نمایش نمودار داده‌ها و مدل‌های آموزشی استفاده خواهیم کرد. matplotlib چندین وابستگی دارد.

نصب

```
pip install matplotlib
```